

第八章

矩阵特征值和特征向量的计算

§ 1 引言

§ 2 乘幂法与反幂法

§ 3* **Jacobi**方法

§ 1 引言

设 \mathbf{A} 为 n 阶方阵，若数 λ 满足

$$\mathbf{Ax} = \lambda \mathbf{x} \quad \mathbf{x} \neq \mathbf{0}$$

则 λ 称为 \mathbf{A} 的一个特征值。非零向量 \mathbf{x} 称为与特征值 λ 对应的特征向量。

求 \mathbf{A} 的特征值，可通过求 $\det(\mathbf{A} - \lambda \mathbf{I}) = 0$ 的 n 个根得到；对应的特征向量可通过求 $(\mathbf{A} - \lambda_i \mathbf{I})\mathbf{x} = \mathbf{0} \quad i = 1, 2, \dots, n$ 的非零解向量得到。

将 $\det(\mathbf{A} - \lambda \mathbf{I}) = 0$ 展开为 λ 的多项式，未必得到精确的特征方程；且 n 增加，计算量迅速增加。

计算矩阵特征值及特征向量的数值方法：**迭代法和变换法**

§ 2 乘幂法与反幂法

一 乘幂法

求按模最大的特征值(主特征值)和相应的特征向量。

基本思想：采用迭代法求实矩阵的主特征值对应的特征向量，进而再求出主特征值。

设 $\mathbf{A} \in \mathbf{R}^{n \times n}$ 的特征值为 $|\lambda_1| \geq |\lambda_2| \geq \cdots \geq |\lambda_n|$ ，对应的特征向量 $\mathbf{x}_1, \mathbf{x}_2, \cdots, \mathbf{x}_n$ 线性无关（构成 \mathbf{R}^n 上的一组基）。
对 $\forall \mathbf{V}^{(0)} \in \mathbf{R}^n$ ($\mathbf{V}^{(0)} \neq \mathbf{0}$)，设 $\mathbf{V}^{(0)} = c_1 \mathbf{x}_1 + c_2 \mathbf{x}_2 + \cdots + c_n \mathbf{x}_n = \sum_{j=1}^n c_j \mathbf{x}_j$

构造
向量
序列

$$\mathbf{V}^{(1)} = \mathbf{A} \mathbf{V}^{(0)} = c_1 \lambda_1 \mathbf{x}_1 + c_2 \lambda_2 \mathbf{x}_2 + \cdots + c_n \lambda_n \mathbf{x}_n = \sum_{j=1}^n c_j \lambda_j \mathbf{x}_j$$

$$\mathbf{V}^{(2)} = \mathbf{A} \mathbf{V}^{(1)} = c_1 \lambda_1^2 \mathbf{x}_1 + c_2 \lambda_2^2 \mathbf{x}_2 + \cdots + c_n \lambda_n^2 \mathbf{x}_n = \sum_{j=1}^n c_j \lambda_j^2 \mathbf{x}_j$$

\vdots

$$\mathbf{V}^{(k)} = \mathbf{A} \mathbf{V}^{(k-1)} = c_1 \lambda_1^k \mathbf{x}_1 + c_2 \lambda_2^k \mathbf{x}_2 + \cdots + c_n \lambda_n^k \mathbf{x}_n = \sum_{j=1}^n c_j \lambda_j^k \mathbf{x}_j$$

即 $\mathbf{V}^{(k)} = \mathbf{A}\mathbf{V}^{(k-1)} = \mathbf{A}(\mathbf{A}\mathbf{V}^{(k-2)}) = \mathbf{A}^2\mathbf{V}^{(k-2)} = \cdots = \mathbf{A}^k\mathbf{V}^{(0)}$

$\mathbf{V}^{(k)}$ 是用 \mathbf{A} 的 k 次幂左乘 $\mathbf{V}^{(0)}$ 得到，故该方法称为**乘幂法**。

分下列情况讨论：

① $|\lambda_1| > |\lambda_j| \ (j = 2, 3, \cdots, n)$ （主特征值是特征方程的单根）

$$\mathbf{V}^{(k)} = \lambda_1^k (c_1 \mathbf{x}_1 + c_2 \left(\frac{\lambda_2}{\lambda_1}\right)^k \mathbf{x}_2 + \cdots + c_n \left(\frac{\lambda_n}{\lambda_1}\right)^k \mathbf{x}_n)$$

若 $c_1 \neq 0$ ，由于 $\left|\frac{\lambda_j}{\lambda_1}\right| < 1 \ (j \geq 2)$ ，当 k 充分大时，

$$\mathbf{V}^{(k)} \approx \lambda_1^k c_1 \mathbf{x}_1$$

即 $\mathbf{V}^{(k)}$ 是相应于 λ_1 的近似特征向量。

设 $V_i^{(k)}$ 表示 $\mathbf{V}^{(k)}$ 的第 i 个分量，则

$$\frac{V_i^{(k+1)}}{V_i^{(k)}} \approx \frac{\lambda_1^{k+1} c_1 (\mathbf{x}_1)_i}{\lambda_1^k c_1 (\mathbf{x}_1)_i} = \lambda_1$$

$$\mathbf{V}^{(k)} = c_1 \lambda_1^k \mathbf{x}_1 + c_2 \lambda_2^k \mathbf{x}_2 + \cdots + c_n \lambda_n^k \mathbf{x}_n$$

$$\mathbf{A}\mathbf{x} = \lambda\mathbf{x} \Rightarrow \mathbf{A}(k\mathbf{x}) = \lambda(k\mathbf{x})$$

② $\lambda_1 = \lambda_2 = \cdots = \lambda_r, |\lambda_1| > |\lambda_{r+1}| \geq \cdots \geq |\lambda_n|$ (主特征值是特征方程的重根)

$$\mathbf{V}^{(k)} = c_1 \lambda_1^k \mathbf{x}_1 + c_2 \lambda_2^k \mathbf{x}_2 + \cdots + c_n \lambda_n^k \mathbf{x}_n = \lambda_1^k \left[\sum_{j=1}^r c_j \mathbf{x}_j + \sum_{j=r+1}^n c_j \left(\frac{\lambda_j}{\lambda_1} \right)^k \mathbf{x}_j \right]$$

若 $c_1 \neq 0, c_2 \neq 0, \cdots, c_r \neq 0$ 由于 $\left| \frac{\lambda_j}{\lambda_1} \right| < 1 (j \geq r+1)$, 当 k 充分大时,

$$\mathbf{V}^{(k)} \approx \lambda_1^k \sum_{j=1}^r c_j \mathbf{x}_j$$

即 $\mathbf{V}^{(k)}$ 仍是相应于 λ_1 的近似特征向量。

且

$$\frac{V_i^{(k+1)}}{V_i^{(k)}} \approx \frac{\lambda_1^{k+1} \left(\sum_{j=1}^r c_j \mathbf{x}_j \right)_i}{\lambda_1^k \left(\sum_{j=1}^r c_j \mathbf{x}_j \right)_i} = \lambda_1$$

Remark 此时 λ_1 的特征向量子空间不是一维, 故 $\mathbf{V}^{(k)}$ 只是相应于 λ_1 的特征子空间中的一个向量, 且从不同的 $\mathbf{V}^{(0)}$ 出发, 得到的 $\mathbf{V}^{(k)}$ 可能线性无关。

$$\mathbf{A}\mathbf{x}_1 = \lambda\mathbf{x}_1, \mathbf{A}\mathbf{x}_2 = \lambda\mathbf{x}_2 \Rightarrow \mathbf{A}(k_1\mathbf{x}_1 + k_2\mathbf{x}_2) = \lambda(k_1\mathbf{x}_1 + k_2\mathbf{x}_2)$$

③ $\lambda_1 = -\lambda_2, |\lambda_1| = |\lambda_2| > |\lambda_j|$ ($j = 3, 4, \dots, n$) (主特征值互为相反实数)

④ $\lambda_1 = \overline{\lambda_2}, |\lambda_1| > |\lambda_3| \geq \dots \geq |\lambda_n|$ (主特征值为特征方程的共轭复根)
(见其他书籍)

具体做法 取 $\forall \mathbf{V}^{(0)} \in \mathbf{R}^n$ ($\mathbf{V}^{(0)} \neq \mathbf{0}$)。

$$\mathbf{V}^{(1)} = \mathbf{A}\mathbf{V}^{(0)} \quad \lambda_1^{(1)} = \frac{V_i^{(1)}}{V_i^{(0)}}$$

$$\mathbf{V}^{(2)} = \mathbf{A}\mathbf{V}^{(1)} \quad \lambda_1^{(2)} = \frac{V_i^{(2)}}{V_i^{(1)}} \quad \text{若 } |\lambda_1^{(2)} - \lambda_1^{(1)}| \leq \varepsilon$$

则 $\lambda_1 \approx \lambda_1^{(2)}$, $\mathbf{V}^{(2)}$ 是与 λ_1 相应的近似特征向量。

否则 $\mathbf{V}^{(3)} = \mathbf{A}\mathbf{V}^{(2)} \quad \lambda_1^{(3)} = \frac{V_i^{(3)}}{V_i^{(2)}} \quad \text{若 } |\lambda_1^{(3)} - \lambda_1^{(2)}| \leq \varepsilon$

则 $\lambda_1 \approx \lambda_1^{(3)}$, $\mathbf{V}^{(3)}$ 是与 λ_1 相应的近似特征向量。……

否则 $\mathbf{V}^{(k+1)} = \mathbf{A}\mathbf{V}^{(k)} \quad \lambda_1^{(k+1)} = \frac{V_i^{(k+1)}}{V_i^{(k)}}, k = 1, 2, \dots \quad \text{若 } |\lambda_1^{(k+1)} - \lambda_1^{(k)}| \leq \varepsilon,$

即 $\frac{V_i^{(k+1)}}{V_i^{(k)}}$ 趋于定值, 则 $\lambda_1 \approx \lambda_1^{(k+1)}$, $\mathbf{V}^{(k+1)}$ 是相应于 λ_1 的近似特征向量。

$$\mathbf{V}^{(k)} = \mathbf{A}\mathbf{V}^{(k-1)}, \mathbf{V}^{(k)} \approx \lambda_1^k c_1 \mathbf{x}_1, \mathbf{V}^{(k)} \approx \lambda_1^k \sum_{j=1}^r c_j \mathbf{x}_j,$$

西北工业 $\lambda_1 \approx V_i^{(k+1)} / V_i^{(k)} \quad V_i^{(k)}$ 为 $\mathbf{V}^{(k)}$ 的第 i 个分量

Remarks

(1) 若计算相邻迭代向量的分量比时，其中某个分量为零，则计算其它分量的比值。

(2) 乘幂法中，迭代向量 $\mathbf{V}^{(k)} = \mathbf{A}\mathbf{V}^{(k-1)}$ 的分量可能会出现绝对值非常大(当 $|\lambda_1| > 1$) 的现象，从而造成计算上溢。特征向量允许相差一个常数因子，实用中常每进行 m 步对迭代向量 $\mathbf{V}^{(k)}$ 做一次规范化。

设 $\max \mathbf{V}^{(k)}$ 表示向量 $\mathbf{V}^{(k)}$ 按模最大的分量。则用 $\tilde{\mathbf{V}}^{(k)} = \frac{\mathbf{V}^{(k)}}{\max \mathbf{V}^{(k)}}$ 代替 $\mathbf{V}^{(k)}$ 继续迭代。 m 取值视情况而定。

$\mathbf{V}^{(k)}$ 分量绝对值非常小(当 $|\lambda_1| < 1$) 时，会造成计算下溢，则用 $\tilde{\mathbf{V}}^{(k)} = \frac{\mathbf{V}^{(k)}}{\min \mathbf{V}^{(k)}}$ 代替 $\mathbf{V}^{(k)}$ 继续迭代。

$$\mathbf{A}\mathbf{x} = \lambda\mathbf{x} \Rightarrow \mathbf{A}(k\mathbf{x}) = \lambda(k\mathbf{x})$$

二 反(逆)幂法

求 \mathbf{A} 按模最小的特征值和相应的特征向量。

设非奇异矩阵 $\mathbf{A} \in \mathbf{R}^{n \times n}$ ，且 \mathbf{A} 无零特征值。

当 \mathbf{A} 的特征值满足 $|\lambda_1| \geq |\lambda_2| \geq \cdots > |\lambda_n| > 0$ ，对应的特征向量为 $\mathbf{x}_1, \mathbf{x}_2, \cdots, \mathbf{x}_n$ 。 \mathbf{A}^{-1} 的特征值满足

$$|1/\lambda_n| > |1/\lambda_{n-1}| \geq \cdots \geq |1/\lambda_1|$$

并且 \mathbf{A} 对应于 λ_n 的特征向量与 \mathbf{A}^{-1} 对应于 $1/\lambda_n$ 的特征向量相同。

对 \mathbf{A}^{-1} 用乘幂法求解的主特征值是 $1/\lambda_n$ ，特征向量是 \mathbf{x}_n 。从而可得 \mathbf{A} 按模最小的特征值 λ_n 及相应的特征向量 \mathbf{x}_n 。

用 \mathbf{A}^{-1} 代替 \mathbf{A} 作乘幂，求 \mathbf{A} 按模最小的特征值及相应特征向量的方法称为反幂法。

西北工业大学 数统学 若 $\mathbf{Ax}=\lambda\mathbf{x}$ ，则 $\mathbf{A}^{-1}\mathbf{x}=\lambda^{-1}\mathbf{x}$

反幂法的计算过程

- ① 任取初始向量 $\mathbf{V}^{(0)} \in \mathbf{R}^n$ ($\mathbf{V}^{(0)} \neq \mathbf{0}$)
- ② 计算 $\mathbf{V}^{(k+1)} = \mathbf{A}^{-1}\mathbf{V}^{(k)} \quad k = 0, 1, 2, \dots$
- ③ 根据 $\mathbf{V}^{(k)}$ 分量的变化趋势，求出 \mathbf{A}^{-1} 按模最大的特征值 $1/\lambda_n$ 及对应特征向量 \mathbf{x}_n 的近似值，从而得到 λ_n 及对应特征向量 \mathbf{x}_n 的近似值。

为避免求逆，上面迭代公式改写为

$$\mathbf{A}\mathbf{V}^{(k+1)} = \mathbf{V}^{(k)}$$

它是反幂法的主要工作量。

每步迭代中，矩阵 \mathbf{A} 不变。故做三角分解 $\mathbf{A}=\mathbf{L}\mathbf{U}$ ，使得每次迭代只需解二个三角形方程组

$$\begin{cases} \mathbf{L}\mathbf{y} = \mathbf{V}^{(k)} \\ \mathbf{U}\mathbf{V}^{(k+1)} = \mathbf{y} \end{cases}$$

反幂法的应用

若 \mathbf{A} 的特征值为 $\lambda_1, \lambda_2, \dots, \lambda_n$ ，对应的特征向量为 $\mathbf{x}_1, \mathbf{x}_2, \dots, \mathbf{x}_n$ 。则 $\mathbf{B} = \mathbf{A} - p\mathbf{I}$ 的特征值为 $\lambda_1 - p, \lambda_2 - p, \dots, \lambda_n - p$ ，对应的特征向量也为 $\mathbf{x}_1, \mathbf{x}_2, \dots, \mathbf{x}_n$ 。

已知矩阵 \mathbf{A} 之特征值 λ_s 的近似值 p ，求特征值 λ_s 及相应的特征向量。

一般有 $0 < |\lambda_s - p| < |\lambda_j - p| \quad (j \neq s)$
 $\mathbf{A} - p\mathbf{I}$ (\mathbf{I} 为单位矩阵) 按模最小的特征值是 $\lambda_s - p$ ，对应的特征向量与 \mathbf{A} 相应于 λ_s 的特征向量相同。

对 $\mathbf{A} - p\mathbf{I}$ 用反幂法（即对 $(\mathbf{A} - p\mathbf{I})^{-1}$ 用乘幂法）。

$$\mathbf{A}\mathbf{x}_i = \lambda_i\mathbf{x}_i \Rightarrow (\mathbf{A} - p\mathbf{I})\mathbf{x}_i = (\lambda_i - p)\mathbf{x}_i$$

对 $\mathbf{A}-p\mathbf{I}$ 用反幂法（即对 $(\mathbf{A}-p\mathbf{I})^{-1}$ 用乘幂法），有

- ① 任取初始向量 $\mathbf{V}^{(0)} \in \mathbf{R}^n$ ($\mathbf{V}^{(0)} \neq \mathbf{0}$)
- ② 计算 $(\mathbf{A}-p\mathbf{I})\mathbf{V}^{(k+1)} = \mathbf{V}^{(k)}$ $k = 0, 1, 2, \dots$ 对 $(\mathbf{A}-p\mathbf{I})^{-1}$ 实施乘幂法
- ③ 根据 $\mathbf{V}^{(k)}$ 分量的变化趋势，求出 $(\mathbf{A}-p\mathbf{I})^{-1}$ 按模最大特征值 $1/(\lambda_s - p)$ 及对应特征向量 \mathbf{x}_s 的近似值。从而得到 λ_s 及对应特征向量 \mathbf{x}_s 的近似值。

$$(\mathbf{A} - p\mathbf{I})^{-1} \mathbf{x}_s = \frac{1}{\lambda_s - p} \mathbf{x}_s \Rightarrow (\mathbf{A} - p\mathbf{I})\mathbf{x}_s = (\lambda_s - p)\mathbf{x}_s \Rightarrow \mathbf{A}\mathbf{x}_s = \lambda_s \mathbf{x}_s$$

总结

特征值、特征向量计算的方法

➤ 迭代法

乘幂法-按模最大的特征值和相应的特征向量

反幂法-按模最小的特征值和相应的特征向量

反幂法的应用-已知特征值的近似值，求该
特征值和相应的特征向量